

CHẴN — Trợ lý chống lừa đảo

Nhóm LuaĐạo · Demo CP6

July 30, 2026

CHẶN — Trợ lý chống lừa đảo

NHÓM LUADAO · DEMO CP6

Luật tự áp: **không có bằng chứng thì không có slide**. Mọi con số dưới đây chạy lại được bằng lệnh ghi trong `eval/` và `evidence/`.

Trang	Thời lượng	Người nói
1. User & Job	45"	(điền)
2. Vì sao chọn tính năng này	45"	(điền)
3. Giải pháp & demo live	2'	(điền)
4. Kết quả đo	45"	(điền)
5. User thật nói gì	45"	(điền)
6. Nếu có thêm 1 tuần	30"	(điền)

1. User & Job · 45"

AI: người 55+ dùng smartphone nhưng ít kinh nghiệm số, **đang cầm máy đọc một tin nhắn vừa đến**, phải quyết trong vài phút.

Việc họ đang cố làm (không có chữ AI):

Biết chắc tin nhắn này thật hay giả **trước khi làm theo** — để không mất tiền, và cũng không phải phiền con cháu mỗi lần nghi ngờ.

Hôm nay họ làm gì, và nó hỏng ở đâu: gọi con cháu (phải chờ, ngại phiền, đêm không gọi được) · tự tra mạng (không biết tra gì) · gọi tổng đài ngân hàng (chờ lâu) · đoán rồi làm liều.

Con số:

15.840 hội thoại lừa đảo · 181.943 tin nhắn đã mining, trong đó **6.391 từ 6 nguồn public dẫn tên được** (PhishVN Mendeley · ChongLuaDao.vn · VNCERT SMS Spam · ConScamBench-278 · Zenodo SCC · EMSCAD).
Script đếm: `evidence/scripts/mine_chan_dataset.py`

Nói thẳng luôn nếu bị hỏi: corpus này cân bằng nhân tạo (mỗi kịch bản ~427 hội thoại, tỉ lệ mất tiền đúng 33,3% ở mọi nhóm), nên nó chứng minh **các mẫu lừa đảo tồn tại và trông thế nào**, không chứng minh tần suất ngoài đời.

2. Vì sao chọn tính năng này · 45”

Ứng viên	Số hội thoại	Quyết định
A. Mạo danh cơ quan chức năng	2.137	CHỌN
B. Chiếm tài khoản người quen	1.282	Làm thêm cuối N1 (L5)
C. Mạo danh ngân hàng	851	Gộp vào A — cùng cơ chế
D. Dụ đầu tư / việc nhẹ lương cao	854	LOẠI

Vì sao loại D — có số đứng sau, không phải cảm tính:

Model trả `unknown` cho “đầu tư sản này lợi nhuận 30%/tháng, đảm bảo không lỗ”. Trọng số `loi_ich_bat_thuong` chỉ **0,08**; cộng tối đa vẫn không chạm ngưỡng `medium` **0,35**. Kịch bản này còn kéo dài nhiều phiên — ngoài tầm một lát cắt 1,5 ngày.

Vì sao chọn A: nhiều nhất (gấp 2,5 lần D), gộp được C, và quyết định gọn trong **một tin nhắn** nên demo được trong 5 phút.

3. Giải pháp & demo live · 2’

Lát cắt một câu:

Khi một người lớn tuổi nhận tin nhắn đáng ngờ và đang phân vân có làm theo hay không, CHẮN **chấm tin nhắn theo 8 dấu hiệu thao túng** và trả về **một mức cảnh báo kèm câu hỏi để họ tự hỏi lại người gửi** — trước khi chuyển tiền hoặc đọc mã OTP.

Automation = augment. Cost-of-error hai chiều đều đắt: báo nhầm → cụ không dám làm việc hợp lệ và **mất niềm tin vào cảnh báo**; bỏ sót → mất tiền, gần như không lấy lại. Nên CHẮN **không quyết thay** — chỉ ra dấu hiệu + câu hỏi để tự kiểm chứng qua kênh chính thức. *Một ngoại lệ*: tin có OTP thì chặn cứng ngay trên máy, vì không có tình huống hợp lệ nào cần người lạ biết mã của bạn.

DEMO TRỰC TIẾP — [HTTPS://CHAN-FLAME.VERCEL.APPSMARTPANTS_PRESERVED_253SMARTPANTS_PRESERVED_254](https://chan-flame.vercel.app/smartpants_preserved_253smartpants_preserved_254)
CASE CHUẨN:

“TÔI LÀ CÁN BỘ CÔNG AN. BÁC PHẢI CHUYỂN TIỀN XÁC MINH TRƯỚC 17H HÔM NAY VÀ KHÔNG ĐƯỢC NÓI VỚI NGƯỜI NHÀ.” → HIGH · TRÚNG MAO DANH THAM QUYỀN + AP_LUC_THOI_GIAN · TRÍCH NGUYỄN VĂN CÂU THAO TÚNG · KÈM HOTLINE CHÍNH THỨC ĐỂ TỰ GỌI.

CASE CHỖ KHÓ — LỖI ĐÃ TÌM RA VÀ ĐÃ SỬA, KHÔNG GIẤU:

“CHÀO BÁC, CON LÀ NHÂN VIÊN NGÂN HÀNG, TÀI KHOẢN CỦA BÁC ĐANG BỊ KHOÁ...” SÁNG NAY CÂU NÀY PASS ÂM THẦM: CỬA LỘC L1 TRÊN MÁY KHÔNG KHỚP REGEX NÀO NÊN TRẢ UNKNOWN TẠI CHỖ VÀ MODEL KHÔNG BAO GIỜ ĐƯỢC GỌI — MÀN HÌNH HIỆN Y HẾT NHƯ ĐÃ CHẤM XONG. ĐÃ SỬA: THÊM RULE ESCALATION + MÀN KẾT QUẢ NAY PHÂN BIỆT “CỬA LỘC GIỮ LẠI” VỚI “MODEL ĐÃ CHẤM”, KÈM NÚT KIỂM TRA KỸ HƠN. → GIỜ TRẢ MEDIUM.

4. KẾT QUẢ ĐO · 45”

QUALITY BAR CHỐT 23:59 N1: $\geq 90\%$ GOLDEN SET ($\geq 18/20$) VÀ RECALL $\geq 90\%$ VÀ FALSE POSITIVE $< 15\%$ VÀ KHÔNG NHÃN TRẤN AN NÀO.

PHÉP ĐO	KẾT QUẢ	BAR
<u>GOLDEN SET 20 CASE</u>	<u>20/20 = 100%</u>	<u>$\geq 90\%$ ✓</u>
<u>136 BIẾN THỂ NHIỀU CHÍNH TẢ</u>	<u>136/136 = 100%</u>	<u>— ✓</u>
<u>RECALL TRÊN 125 TIN LỪA ĐẢO</u>	<u>93,6%</u>	<u>$\geq 90\%$ ✓</u>
<u>FALSE POSITIVE TRÊN 73 TIN HỢP LỆ</u>	<u>8,2%</u>	<u>$< 15\%$ ✓</u>

ĐẠT BAR KHÔNG CÓ NGHĨA LÀ XONG — BA THỨ PHẢI NÓI RA:

- 20/20 KHÔNG CHỨNG MINH BỘ CASE ĐỦ KHÓ. PROBE 36 CÂU SOAN ĐỘC LẬP SAU ĐÓ CHỈ ĐƯỢC 22/24 RECALL VÀ 3/12 BÁO NHẦM — TỆ HƠN HẸN BỘ 20 CASE. GOLDEN SET ĐANG ĐO LAI THỨ NHÓM ĐÃ BIẾT.
- FAILURE NGUY HIỂM NHẤT: "NHÀ TRƯỜNG THÔNG BÁO HỌC PHÍ HỌC KỲ 2 LÀ 3 TRIỆU, PHỤ HUYNH NỘP TẠI PHÒNG KẾ TOÁN" → HIGH + MAO DANH THAM QUYEN. TIN NHẮN THẬT BỊ HẾT LÊN MỨC CAO NHẤT. VỚI NGƯỜI 60 TUỔI, SAI KIỂU NÀY ĐẮT HƠN BỎ SÓT: HỌ KHÔNG NỘP HỌC PHÍ, VÀ LẦN SAU KHÔNG TIN CẢNH BÁO NỮA.
- L5 (PHÁT HIỆN CHIẾM TÀI KHOẢN) ĐO TRÊN 1.282 HỘI THOẠI THẬT: RECALL 0. VÌ 1.132/1.282 HỘI THOẠI HỎI TIỀN NGAY SAU 1 TIN NHẮN VÀ 0 HỘI THOẠI NÀO NẠN NHÂN ĐÒI GỌI VIDEO — CORPUS KHÔNG CÓ PHẦN "TRƯỚC ĐÓ" ĐỂ SO. GHI NGUYÊN, VÀ L5 ĐƯỢC KHAI LÀ NGOÀI LÁT CẮT, CHƯA VALIDATE.

5. USER THẬT NÓI GÌ · 45”

⚠️ TRANG NÀY CHƯA CÓ NỘI DUNG — ĐIỀN SAU VÒNG VALIDATION SÁNG CP5. CẦN ≥ 2 QUOTE NGUYÊN VĂN KÈM TÊN/VAI + 1 THAY ĐỔI ĐÃ LÀM TỪ FEEDBACK. KÍCH BẢN CHẠY VÒNG VALIDATION: [VALIDATION/SESSION-SCRIPT.MD](#)

- QUOTE 1 (TÊN/VAI):
- QUOTE 2 (TÊN/VAI):
- THAY ĐỔI ĐÃ LÀM TỪ FEEDBACK:

6. Nếu có thêm 1 tuần · 30”

- Hiệu chỉnh lại trọng số L4.** Đo được: với `scam_confidence = 0` có 21 tổ hợp dấu hiệu không bao giờ chạm nổi `medium` dù `confidence = 1.0` — kể cả tổ hợp 3 dấu hiệu. Nghĩa là 8 trọng số hiện gần như không quyết định gì, một mình `scam_confidence` gánh hết.

2. **Golden set từ dữ liệu thật.** Hiện 0/20 case đến từ chatlog thật; và corpus training chỉ có **8,1% câu khác nhau** trong nhóm chiếm tài khoản — model dễ thuộc template thay vì hiểu kịch bản.
3. **Thu luồng chat có lịch sử trước lúc bị chiếm**, thứ duy nhất kiểm được L5.

Bài học lớn nhất:

Bug tệ nhất hôm nay không phải model đoán sai — mà là màn hình **trình bày một quyết định chưa hề xảy ra y như một quyết định đã xảy ra**. Người dùng không phân biệt được “chưa kiểm” và “kiểm rồi không thấy gì”, trong khi khoảng cách giữa hai câu đó chính là toàn bộ giá trị của sản phẩm.

Cả nhóm phải trả lời được

- “**Augment hay automate — vì sao?**” → augment; cost-of-error hai chiều đều đắt và người chịu hậu quả không phải nhóm build. Ngoại lệ OTP chặn cứng.
- “**Failure nguy hiểm nhất?**” → tin nhắn học phí thật bị gán `high`.
- “**Phần bạn làm là gì?**” → mỗi người mở đúng file có tên mình trong `README.md` và giải thích được.

Backup demo

- ☐ Screenshot/video ngăn phòng live hòng — lưu tại `codebase/demo-backup/`